

Estabilidade Numérica - Equações Rígidas & Domínio de Estabilidade

Gabriel Bufolo

Junho 2025

Ressalva: Estabilidade numérica é um tópico que ainda está em sua infância e muita pesquisa ainda é feita atualmente neste assunto. Naturalmente, muito do que se sabe sobre o assunto atualmente é restrito à casos particulares e vários conceitos ainda escapam definições matemática precisas. Levem isso em consideração durante essas aulas.

1 Um exemplo introdutório

Sejam $N \in \mathbb{N}$, $\phi : \mathbb{R} \rightarrow \mathbb{R}^N$, $A \in \mathcal{M}_{N \times N}(\mathbb{R})$ (i.e., A é uma matriz N por N) que possui N autovalores **reais negativos** distintos e $y_0 \in \mathbb{R}$ e considere o P.V.I.

$$\begin{cases} y'(t) &= Ay(t) + \phi(t); \\ y(0) &= y_0, \end{cases}$$

onde buscamos uma $y : \mathbb{R} \rightarrow \mathbb{R}^N$. Este P.V.I. está associado a uma E.D.O. não-homogênea e, por Cálculo II, sabemos que sua solução geral será da forma

$$y(t) = y_h(t) + y_p(t),$$

onde y_p é uma solução particular do problema apresentado e y_h é a solução geral para o problema homogêneo associado (i.e., $\phi \equiv 0$) com suas constantes arbitrárias dependendo não só da condição inicial, mas também da escolha particular de y_p . Ainda da teoria apresentada em Cálculo II, sabemos que

$$y_h(t) = \sum_{i=1}^N c_i e^{\lambda_i t} v_i,$$

$\lambda_i \in (-\infty, 0)$ são os autovalores de A , cada $v_i \in \mathbb{R}^N$ é o autovetor associado à λ_i e $c_i \in \mathbb{R}$ são as constantes arbitrárias. Como assumimos que todos os autovalores de A são negativos, temos que

$$\lim_{t \rightarrow \infty} y_h(t) = \lim_{t \rightarrow \infty} \sum_{i=1}^N c_i e^{\lambda_i t} v_i = 0.$$

Então, dado $\epsilon \in (0, \infty)$, existe $T \in (0, \infty)$ tal que

$$\|y(t) - y_p(t)\| < \epsilon,$$

para todo $t \in [T, \infty)$, i.e. a solução geral do P.V.I. fica arbitrariamente próxima da solução particular para t grande. Neste tipo de situação, dizemos que y_h é uma solução transiente e y_p é uma solução permanente. Ao resolver numericamente este tipo de problemas, normalmente deseja-se integrar a solução (pelo menos) até que y_h se torne "insignificante" perante y_p . Note que o que vai determinar a velocidade de decaimento de y_h e, portanto, quanto tempo leva para a solução transiente se tornar "insignificante" é o autovalor de menor valor absoluto, que chamaremos de λ .

Vamos, por hora, deixar a solução analítica de lado e analisar o que acontece quando tentamos integrar o P.V.I. original com o método de Euler. Ao discretizar num passo $n \in \mathbb{N}$ arbitrário, obtemos que

$$y_{n+1} = y_n + h(Ay_n + \phi(t_n)) = (\mathbb{I} + hA)y_n + h\phi(t_n),$$

onde $h \in (0, \infty)$ é o passo de tempo e $\mathbb{I} \in \mathcal{M}_{N \times N}(\mathbb{R})$ é a matriz identidade em N dimensões.

Substituindo a condição inicial e avançando um passo, obtemos

$$y_1 = (\mathbb{I} + hA)y_0 + h\phi(t_0).$$

No segundo passo, temos que

$$\begin{aligned} y_2 &= (\mathbb{I} + hA)y_1 + h\phi(t_1) = (\mathbb{I} + hA)((\mathbb{I} + hA)y_0 + h\phi(t_0)) + h\phi(t_1) \\ &= (\mathbb{I} + hA)^2 y_0 + (\mathbb{I} + hA)h\phi(t_0) + h\phi(t_1). \end{aligned}$$

Já no terceiro passo,

$$\begin{aligned} y_3 &= (\mathbb{I} + hA)y_2 + h\phi(t_1) \\ &= (\mathbb{I} + hA)\left((\mathbb{I} + hA)^2 y_0 + (\mathbb{I} + hA)h\phi(t_0) + h\phi(t_1)\right) + h\phi(t_2) \\ &= (\mathbb{I} + hA)^3 y_0 + (\mathbb{I} + hA)^2 h\phi(t_0) + (\mathbb{I} + hA)h\phi(t_1) + h\phi(t_2) \\ &= (\mathbb{I} + hA)^3 y_0 + h \sum_{i=0}^2 (\mathbb{I} + hA)^{2-i} \phi(t_i), \end{aligned}$$

nós começamos a notar um padrão. De fato, um argumento por indução nos mostra que o n -ésimo passo será dado por

$$y_n = (\mathbb{I} + hA)^n y_0 + h \sum_{i=0}^{n-1} (\mathbb{I} + hA)^{n-1-i} \phi(t_i).$$

Esta expressão explícita de y_n nos sugere que é importante analisar o termo $(\mathbb{I} + hA)^n$, para $n \in \mathbb{N}$.

Como supusemos que A possui N autovalores distintos (o que implica que a soma dos autoespaços de A é N), temos que para

$$D := \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

existe $V \in \mathcal{M}_{N \times N}(\mathbb{R})$ invertível tal que

$$A = VDV^{-1}.$$

Desta forma,

$$\begin{aligned} (\mathbb{I} + hA)^n &= (\mathbb{I} + hVDV^{-1})^n = (VV^{-1} + hVDV^{-1})^n = (V\mathbb{I}V^{-1} + VhDV^{-1})^n \\ &= (V(\mathbb{I} + hD)V^{-1})^n \\ &= \underbrace{V(\mathbb{I} + hD)V^{-1}V(\mathbb{I} + hD)V^{-1} \dots V(\mathbb{I} + hD)V^{-1}V(\mathbb{I} + hD)V^{-1}}_{n\text{-times}} \\ &= V \underbrace{(\mathbb{I} + hD) \dots (\mathbb{I} + hD)}_{n\text{-times}} V^{-1} = V(\mathbb{I} + hD)^n V^{-1} \\ &= V \begin{bmatrix} 1 + h\lambda_1 & 0 & \cdots & 0 \\ 0 & 1 + h\lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 + h\lambda_n \end{bmatrix}^n V^{-1} \\ &= V \begin{bmatrix} (1 + h\lambda_1)^n & 0 & \cdots & 0 \\ 0 & (1 + h\lambda_2)^n & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & (1 + h\lambda_n)^n \end{bmatrix} V^{-1}, \end{aligned}$$

onde foi usado que elevar uma matriz diagonal a uma potência inteira é equivalente a elevar os elementos diagonais da matriz original por esta mesma potência. Note que a solução transiente (numérica) só irá decair se $|1 + h\lambda_i| < 1$. Desta forma, a equação diferencial e o método numérico combinados impõem a condição

$$|1 + h\lambda_i| < 1 \iff -1 < 1 + h\lambda_i < 1 \iff -2 < h\lambda_i < 0 \iff h < \frac{2}{|\lambda_i|},$$

para todo $i \in [1, N] \cap \mathbb{N}$. Como isso tem que ser válido para todos os autovalores e os mesmos aparecem no denominador da expressão, temos que $h < \frac{2}{|\bar{\lambda}|}$, onde $\bar{\lambda}$ é o autovalor de maior valor absoluto.

Combinando o que observamos da solução analítica e numérica do P.V.I., nos deparamos com o cerne da questão: a solução analítica sugere que devemos integrar a solução em um intervalo de tempo fica maior conforme $\underline{\lambda}$ diminui,

enquanto a solução numérica nos impõe um passo de tempo que fica menor conforme $\bar{\lambda}$ aumenta. O problema é que esses dois autovalores são, normalmente, completamente independentes e podem ter ordens de magnitude completamente diferentes! Neste caso, podemos ser forçados a usar um passo de tempo muito pequeno para garantir que a solução transiente se torne "insignificante" enquanto queremos realizar uma integração numérica em um intervalo de tempo muito grande para garantir a "insignificância" da solução transiente.

Exemplo: Considere

$$A = \begin{bmatrix} -100 & 0 \\ 0 & -\frac{1}{10} \end{bmatrix}.$$

A solução transiente seria dada por

$$y_h(t) = \left(c_1 e^{-10000t}, c_2 e^{-\frac{t}{10}} \right),$$

onde $c_1, c_2 \in \mathbb{R}$ são as constantes arbitrárias. Assumindo que tais constantes $c_1, c_2 = 1$ e colocando o limiar 10^{-3} de "insignificância" para solução transiente, precisaremos integrar esta solução além de $t = 69$. Por outro lado, precisaremos utilizar um passo de tempo $h < \frac{2}{10000} = 2 \times 10^{-4}$. Ou seja, precisaremos realizar quase 350000 passos até a solução transiente se tornar "insignificante".

Definição 1. *Sejam $N \in \mathbb{N}$, $\phi : \mathbb{R} \rightarrow \mathbb{R}^N$, $A \in \mathcal{M}_{N \times N}(\mathbb{R})$, com N autovalores distintos não-nulos, e $\lambda_i \in \mathbb{C} - \{0\}$ os respectivos N autovalores distintos de A . Definimos o coeficiente de rigidez associado à equação*

$$y'(t) = Ay(t) + \phi(t)$$

como o valor

$$\eta := \frac{\max \{ |\lambda_i| \in \mathbb{R} \mid i \in [1, N] \cap \mathbb{N} \}}{\min \{ |\lambda_i| \in \mathbb{R} \mid i \in [1, N] \cap \mathbb{N} \}}.$$

Observação 1. *Nesta definição os autovalores de A podem ser complexos.*

Observação 2. *Essa definição, apesar de formal, é heurística. Digo isto pois ela é baseada em um estudo feito com um método numérico particular, onde a matriz A tem autovalores "bem comportados". Apesar disto, ela cumpre bem o papel para qual foi estabelecida.*

Observação 3. *Embora ainda não haja consenso sobre uma definição formal para equação rígida, eu particularmente gosto da seguinte (informal) "regra de ouro": Uma equação é rígida quando sua convergência (e **não sua precisão!**) impõe restrições na escolha do passo de tempo. Note que nesta "regra de ouro" não há nenhuma menção de método numérico, o que mostra que ela não é totalmente apropriada.*

Observação 4. *No caso mais geral da equação*

$$y'(t) = f(y, t),$$

onde $f : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}^N$ é Lipschitz, pode-se usar um argumento de linearização para fazer uma análise similar (mas bem mais complicada) a que fizemos. Daí, a definição acima pode ser estendida para a equação mais geral, onde os autovalores de A são substituídos pelos autovalores do Jacobiano de f . Neste caso, o coeficiente de rigidez da equação pode depender do tempo, i.e., a equação pode ter rigidez diferente em intervalos de tempo diferentes.

2 A-estabilidade

2.1 Exemplo: método de Euler

Sejam $y_0 \in \mathbb{R}$, $\lambda \in \mathbb{C}$ com $\Re(\lambda) < 0$ e considere o P.V.I.

$$\begin{cases} y'(t) &= \lambda y(t); \\ y(0) &= y_0, \end{cases}$$

onde buscamos $y : \mathbb{R} \rightarrow \mathbb{R}$. Podemos expandir o processo iterativo proveniente do método de Euler para esse novo P.V.I. usando os mesmos argumentos do problema não homogêneo. Neste caso, obteremos

$$y_n = (1 + h\lambda)^n y_0,$$

onde $h \in (0, \infty)$ é o passo de tempo. Para que este processo iterativo seja convergente quando $n \rightarrow \infty$, precisamos que

$$|1 + z| < 1,$$

onde $h\lambda =: z \in \mathbb{C}$. Escrevendo $z = a + bi$ e usando a definição do valor absoluto de um número complexo, obtemos que

$$(1 + a)^2 + b^2 < 1 = 1^2,$$

que descreve o interior de um círculo no plano complexo. Mais precisamente, o interior do círculo unitário cujo centro é -1 .

2.2 Métodos de Runge-Kutta explícitos

Como já vimos, o método de Euler é um caso particular dos métodos de Runge-Kutta explícitos. Em geral, a expressão de um método de Runge-Kutta explícito arbitrário é dada por

$$y_{n+1} = y_n + h \sum_{i=1}^s b_i k_{n,i},$$

onde $s \in \mathbb{N}$ e os $k_{n,i} \in \mathbb{R}$ são definidos recursivamente através da expressão

$$k_{n,i} := f \left(t_n + c_i h, y_n + h \sum_{j=1}^{i-1} a_{i,j} k_{n,j} \right),$$

para constantes $b_i, c_i, a_{i,j} \in \mathbb{R}$ com $c_1 = 0$ e $f : \mathbb{R} \times \mathbb{C} \rightarrow \mathbb{R}$ é a função no lado direito da E.D.O. a ser integrada.

Observação 5. Como o somatório na definição de $k_{n,i}$ vai de $j = 1$ até $i - 1$, a expressão de $k_{n,1}$ omite a soma e, portanto, não depende nenhum $k_{n,i}$. Similarmente, a definição de um $k_{n,i}$ para algum i particular só vai depender dos $k_{n,i}$ com i menos que aquele particular, i.e., os $k_{n,i}$ estão bem definidos por essa expressão apenas.

De fato, a expressão dos $k_{n,i}$ assume uma forma especial quando $f(t, y) = \lambda y$.

Proposição 1. Sejam $f : \mathbb{R} \times \mathbb{C} \rightarrow \mathbb{C}$, $h, t \in \mathbb{R}$, $y \in \mathbb{C}$ e $a_{i,j}, c_i \in \mathbb{R}$, para todo $i, j \in \mathbb{N}$, com $c_1 = 0$. Para cada $i \in \mathbb{N}$, considere

$$k_i := f \left(t + c_i h, y + h \sum_{j=1}^{i-1} a_{i,j} k_j \right).$$

Se existir $\lambda \in \mathbb{C}$ tal que $f(\tilde{t}, \tilde{y}) = \lambda \tilde{y}$, para todo $\tilde{t} \in \mathbb{R}$ e $\tilde{y} \in \mathbb{C}$, então existem $\phi_i : \mathbb{C} \rightarrow \mathbb{C}$ para todo $i \in \mathbb{N}$ tal que

$$h k_i = \phi_i(h\lambda) y.$$

Demonstração. Vamos fazer a provar por indução em i .

Base Para $i = 1$, considere $\phi(z) := z$. Então, temos que

$$h k_1 = h f \left(t + c_1 h, y + h \sum_{j=1}^{1-1} a_{1,j} k_j \right) = h f(t, y) = h \lambda y = \phi_1(h\lambda) y,$$

pois $c_1 = 0$ e $f(t, y) = \lambda y$, por hipótese.

Indução Suponha que existe $i_0 \in \mathbb{N}$ tal que, para todo $i \in [1, i_0] \cap \mathbb{N}$, existem $\phi_i : \mathbb{C} \rightarrow \mathbb{C}$ para os quais

$$h k_i = \phi_i(h\lambda) y.$$

Como, por hipótese, $f(\tilde{t}, \tilde{y}) = \lambda \tilde{y}$ para todo $\tilde{t} \in \mathbb{R}, \tilde{y} \in \mathbb{C}$, a definição de

k_{i_0+1} nos dá

$$\begin{aligned}
hk_{i_0+1} &= hf \left(t + c_{i_0+1}h, y + h \sum_{j=1}^{(i_0+1)-1} a_{i_0+1,j} k_j \right) \\
&= hf \left(t + c_{i_0+1}h, y + h \sum_{j=1}^{i_0} a_{i_0+1,j} k_j \right) \\
&= \left(y + h \sum_{j=1}^{i_0} a_{i_0+1,j} k_j \right) h\lambda \\
&= \left(y + \sum_{j=1}^{i_0} a_{i_0+1,j} h k_j \right) h\lambda
\end{aligned}$$

Então, a hipótese indutiva nos leva a

$$\begin{aligned}
hk_{i_0+1} &= \left(y + \sum_{j=1}^{i_0} a_{i_0+1,j} h k_j \right) h\lambda \\
&= \left(y + \sum_{j=1}^{i_0} a_{i_0+1,j} y \phi_j(h\lambda) \right) h\lambda \\
&= \left(1 + \sum_{j=1}^{i_0} a_{i_0+1,j} \phi_j(h\lambda) \right) h\lambda y \\
&= \phi_{i_0+1}(h\lambda) y,
\end{aligned}$$

para

$$\phi_{i_0+1}(z) := \left(1 + \sum_{j=1}^{i_0} a_{i_0+1,j} \phi_j(z) \right) z.$$

□

Com isso, podemos provar uma forma geral pro processo iterativo de qualquer método de Runge-Kuta explícito aplicado ao P.V.I. anterior. Essa forma geral é bastante similar àquela que obtivemos ao aplicar o método de Euler ao P.V.I. anterior e nos permitirá enunciar uma definição estabelecendo regiões no plano complexo com propósito similar ao círculo unitário com centro -1 que obtivemos naquele caso.

Proposição 2. *Sejam $y_0 \in \mathbb{R}$, $\lambda \in \mathbb{C}$ e considere o P.V.I.*

$$\begin{cases} y'(t) &= \lambda y(t); \\ y(0) &= y_0. \end{cases}$$

Para cada método de Runge-Kutta explícito aplicado a este P.V.I., existe uma $\phi : \mathbb{C} \rightarrow \mathbb{C}$ tal que

$$y_n = \phi(h\lambda)^n y_0,$$

onde $h \in (0, \infty)$ é o passo de tempo e $n \in \mathbb{N} \cup \{0\}$.

Demonstração. Da definição de métodos de Runge-Kutta explícito, sabemos que, para todo $n \in \mathbb{N} \cup \{0\}$,

$$y_{n+1} = y_n + h \sum_{i=1}^s b_i k_{n,i},$$

onde $s \in \mathbb{N}$ e os $k_{n,i} \in \mathbb{R}$ são definidos recursivamente através da expressão

$$k_{n,i} := f \left(t_n + c_i h, y_n + h \sum_{j=1}^{i-1} a_{i,j} k_{n,j} \right),$$

para constantes $a_{i,j}, b_i, c_i \in \mathbb{R}$ com $c_1 = 0$. Note que a escolha do método específico que determina $s, a_{i,j}, b_i, c_i$.

Como, para cada $n \in \mathbb{N} \cup \{0\}$, os $k_{n,i}$ se encaixam na definição de k_i da proposição 1, onde y_n faz o papel aqui do y daquela proposição, e todas as demais hipóteses daquela proposição são satisfeitas, podemos usá-la e obter que, para todo $n \in \mathbb{N}$ e $i \in [1, s] \cap \mathbb{N}$, existem $\phi_{n,i} : \mathbb{C} \rightarrow \mathbb{C}$ tais que

$$h k_{n,i} = \phi_{n,i}(h\lambda) y_n,$$

onde usamos a proposição 1 individualmente para cada n .

Vamos agora mostrar por indução em i que, dados $n_0, n_1 \in \mathbb{N}$, $\phi_{n_0,i}(h\lambda) = \phi_{n_1,i}(h\lambda)$, para todo $i \in [1, s] \cap \mathbb{N}$.

Base Para $i = 1$, temos que

$$\phi_{n_0,1}(z) = z = \phi_{n_1,1}.$$

Este fato vem direto da demonstração da proposição 1. Como usamos aquele resultado individualmente para cada n , a expressão de ϕ_1 obtida naquela demonstração é a mesma para todo n .

Indução Suponha que existe $i_0 \in \mathbb{N}$ tal que $\phi_{n_0,i}(h\lambda) = \phi_{n_1,i}(h\lambda)$, para todo $i \in [1, s] \cap \mathbb{N}$. Se $i_0 \geq \min\{n_0, n_1\}$, não temos mais nada para fazer. Caso contrário, da definição de $k_{n,i}$, do fato de $f(\lambda, t)$ e do nosso uso anterior

da proposição 1, temos que

$$\begin{aligned}
y_n \phi_{n,i_0+1}(h\lambda) &= k_{n,i_0+1} = hf \left(t_n + c_i h, y_n + h \sum_{j=1}^{(i_0+1)-1} a_{i_0+1,j} k_{n,j} \right) \\
&= \left(y_n + h \sum_{j=1}^{i_0} a_{i_0+1,j} k_{n,j} \right) h\lambda \\
&= \left(y_n + \sum_{j=1}^{i_0} a_{i_0+1,j} h k_{n,j} \right) h\lambda \\
&= \left(y_n + \sum_{j=1}^{i_0} a_{i_0+1,j} y_n \phi_{n,j}(h\lambda) \right) h\lambda \\
&= \left(1 + \sum_{j=1}^{i_0} a_{i_0+1,j} \phi_{n,j}(h\lambda) \right) h\lambda y_n,
\end{aligned}$$

para qualquer $n \geq i_0 + 1$. Dividindo ambos os lados por y_n , podemos observar que

$$\phi_{n,i_0+1}(h\lambda) = \left(1 + \sum_{j=1}^{i_0} a_{i_0+1,j} \phi_{n,j}(h\lambda) \right) h\lambda.$$

Como $n \in \mathbb{N} \cup \{0\}$ é arbitrário (desde que seja menor que $i_0 + 1$, o que n_0 e n_1 satisfazem), podemos fazer $n = n_0$ e $n = n_1$ e obter

$$\begin{aligned}
\phi_{n_0,i_0+1}(h\lambda) &= \left(1 + \sum_{j=1}^{i_0} a_{i_0+1,j} \phi_{n_0,j}(h\lambda) \right) h\lambda, \\
\phi_{n_1,i_0+1}(h\lambda) &= \left(1 + \sum_{j=1}^{i_0} a_{i_0+1,j} \phi_{n_1,j}(h\lambda) \right) h\lambda.
\end{aligned}$$

No entanto, como os somatórios vão apenas até i_0 , podemos usar a hipótese indutiva para obter

$$\begin{aligned}
\phi_{n_0,i_0+1}(h\lambda) &= \left(1 + \sum_{j=1}^{i_0} a_{i_0+1,j} \phi_{n_0,j}(h\lambda) \right) h\lambda \\
&= \left(1 + \sum_{j=1}^{i_0} a_{i_0+1,j} \phi_{n_1,j}(h\lambda) \right) h\lambda = \phi_{n_1,i_0+1}(h\lambda),
\end{aligned}$$

o que conclui a indução.

Voltando à demonstração do resultado principal, podemos substituir a expressão encontrada para $hk_{n,i}$ na fórmula do avanço de passo do método e utilizar o resultado recém provado para obter

$$\begin{aligned} y_{n+1} &= y_n + h \sum_{i=1}^s b_i k_{n,i} = y_n + \sum_{i=1}^s b_i h k_{n,i} = y_n + \sum_{i=1}^s b_i y_n \phi_{n,i}(h\lambda) \\ &= \left(1 + \sum_{i=1}^s b_i \phi_{n,i}(h\lambda) \right) y_n = \left(1 + \sum_{i=1}^s b_i \phi_{s,i}(h\lambda) \right) y_n = \phi(h\lambda) y_n, \end{aligned}$$

para $\phi(z) = 1 + \sum_{i=1}^s b_i \phi_{s,i}(z)$.

Vamos então utilizar mais uma indução, agora em $n \in \mathbb{N} \cup \{0\}$, para concluir a demonstração.

Base Para $n = 0$ a condição inicial do P.V.I. nos dá

$$y_0 = 1y_0 = \phi(h\lambda)^0 y_0,$$

que é o que precisaríamos mostrar.

Indução Suponha que existe $n_0 \in \mathbb{N} \cup \{0\}$ tal que

$$y_n = \phi(h\lambda)^n y_0,$$

para todo $n \in [0, n_0] \cap (\mathbb{N} \cup \{0\})$. Usando a hipótese indutiva na expressão obtida anteriormente, concluímos que

$$y_{n_0+1} = \phi(h\lambda) y_{n_0} = \phi(h\lambda) \phi(h\lambda)^{n_0} y_0 = \phi(h\lambda)^{n_0+1} y_0,$$

o que conclui a indução e demonstração. $\square$

Definição 2. Para cada método de Runge-Kutta explícito, a função $\phi : \mathbb{C} \rightarrow \mathbb{C}$ em proposição 2 é chamada de função de estabilidade daquele método.

Com o mesmo raciocínio que nos fez definir encontrar o círculo no plano complexo para o método de Euler, podemos definir outras regiões, uma para cada método de Runge-Kutta explícito.

Definição 3. Para cada método de Runge-Kutta explícito, seja $\phi : \mathbb{C} \rightarrow \mathbb{C}$ sua função de estabilidade. Definimos o domínio de estabilidade daquele método como sendo o conjunto

$$\{z \in \mathbb{C} \mid |\phi(z)| < 1\}.$$

Quando algum método aplicado ao P.V.I. anterior tem a propriedade que todos os possíveis valores de $h \in \mathbb{R}$ e $\lambda \in \mathbb{C}$ com $\Re(\lambda) < 0$ resultam em um processo iterativo convergente, este método recebe um nome especial.

Definição 4. Seja $E \subset \mathbb{C}$ o domínio de estabilidade de um método de Runge-Kutta explícito. Se

$$\{z \in \mathbb{C} \mid \Re(z) < 0\} \subset E,$$

dizemos que tal método de Runge-Kutta é A-estável (absolutamente estável).

Observação 6. As definições de função de estabilidade e domínio de estabilidade de um método de Runge-Kutta explícito são baseadas exclusivamente na equação $y' = \lambda y$. Apesar disso, é uma boa heurística respeitar o domínio de estabilidade do método ao integrar equações mais intrincadas.

Exemplo: Vamos encontrar a função e o domínio de estabilidade do método de Runge-Kutta **clássico** (RK4). Fazendo $f(t, y) = \lambda y$, obtemos as seguintes expressões para os incrementos:

$$\begin{aligned} k_1 &= f(t_n, y_n) = \lambda y_n; \\ k_2 &= f\left(t_n + \frac{h}{2}, y_n + \frac{h}{2}k_1\right) = \lambda\left(y_n + \frac{h}{2}k_1\right) = \lambda\left(y_n + \frac{h}{2}\lambda y_n\right) \\ &= \lambda\left(1 + \frac{h\lambda}{2}\right)y_n; \\ k_3 &= f\left(t_n + \frac{h}{2}, y_n + \frac{h}{2}k_2\right) = \lambda\left(y_n + \frac{h}{2}k_2\right) = \lambda\left(y_n + \frac{h}{2}\lambda\left(1 + \frac{h\lambda}{2}\right)y_n\right) \\ &= \lambda\left(1 + \frac{h\lambda}{2}\left(1 + \frac{h\lambda}{2}\right)\right)y_n; \\ k_4 &= f(t_n + h, y_n + hk_3) = \lambda(y_n + hk_3) = \lambda\left(y_n + h\lambda\left(1 + \frac{h\lambda}{2}\left(1 + \frac{h\lambda}{2}\right)\right)y_n\right) \\ &= \lambda\left(1 + h\lambda\left(1 + \frac{h\lambda}{2}\left(1 + \frac{h\lambda}{2}\right)\right)\right)y_n. \end{aligned}$$

Se multiplicarmos ambos os lados de cada uma dessas equações por h e lembrarmos que cada ϕ_i deve satisfazer $hk_i = y_n\phi_i(h\lambda)$, concluímos que

$$\begin{aligned} \phi_1(z) &= z, \\ \phi_2(z) &= \left(1 + \frac{z}{2}\right)z = z + \frac{z^2}{2}, \\ \phi_3(z) &= \left(1 + \frac{z}{2}\left(1 + \frac{z}{2}\right)\right)z = z + \frac{z^2}{2} + \frac{z^3}{4}, \\ \phi_4(z) &= \left(1 + z\left(1 + \frac{z}{2}\left(1 + \frac{z}{2}\right)\right)\right)z = z + z^2 + \frac{z^3}{2} + \frac{z^4}{4}. \end{aligned}$$

Lembrem que a expressão obtida na demonstração da proposição 2 para a ϕ em termos das ϕ_i era

$$\phi(z) = 1 + \sum_{i=1}^s b_i \phi_i(z),$$


onde os b_i são os pesos dos incrementos na expressão final do avanço do passo. Como no método RK4 o avanço de passo é dado por

$$y_{n+1} = y_n + h\left(\frac{k_1}{6} + \frac{k_2}{3} + \frac{k_3}{3} + \frac{k_4}{6}\right),$$

temos que $b_1 = \frac{1}{6}, b_2 = \frac{1}{3}, b_3 = \frac{1}{3}, b_4 = \frac{1}{6}$. Então:

$$\begin{aligned}
 \phi(z) &= 1 + \frac{\phi_1(z)}{6} + \frac{\phi_2(z)}{3} + \frac{\phi_3(z)}{3} + \frac{\phi_4(z)}{6} \\
 &= 1 + \frac{z}{6} + \frac{z + \frac{z^2}{2}}{3} + \frac{z + \frac{z^2}{2} + \frac{z^3}{4}}{3} + \frac{z + z^2 + \frac{z^3}{2} + \frac{z^4}{4}}{6} \\
 &= 1 + \frac{z}{6} + \frac{z}{3} + \frac{z^2}{6} + \frac{z}{3} + \frac{z^2}{6} + \frac{z^3}{12} + \frac{z}{6} + \frac{z^2}{6} + \frac{z^3}{12} + \frac{z^4}{24} \\
 &= 1 + z + \frac{z^2}{2} + \frac{z^3}{6} + \frac{z^4}{24} = \sum_{i=0}^4 \frac{z^i}{i!}.
 \end{aligned} \tag{1}$$

De posse da função de estabilidade do método RK4, podemos utilizar softwares gráficos para traçar seu domínio de estabilidade.



Teorema 1. *Nenhum método de Runge-Kutta explícito é A-estável.*

Demonstração. Basta observar na demonstração da proposição 1 que

$$\phi_i(z) = \left(1 + \sum_{j=1}^{i-1} a_{i,j} \phi_j(z) \right) z,$$

para todo $i \in \mathbb{N}$. Note que quando $i = 1$, o somatório na equação acima desaparece e caímos no caso $\phi_1(z) = z$ encontrado previamente, i.e., a equação

acima determina recursivamente todas as ϕ_i . Daí, concluímos que todas as ϕ_i são polinômios. Ademais, na demonstração de proposição 2, vimos que

$$\phi(z) = 1 + \sum_{i=1}^s b_i \phi_i(z),$$

donde concluímos que ϕ é sempre um polinômio complexo. Como, para todo $z \in \mathbb{C}$ e $p : \mathbb{C} \rightarrow \mathbb{C}$ polinomial, sabemos que

$$\lim_{t \rightarrow \infty} |p(tz)| = \infty,$$

concluímos que o domínio de estabilidade de um método de Runge-Kutta explícito é uma região limitada em $\mathbb{C}$, o que conclui a demonstração. $\square$

2.3 Métodos de Runge-Kutta implícitos

Teorema 2. *Sejam $y_0 \in \mathbb{R}$, $\lambda \in \mathbb{C}$ e considere o P.V.I.*

$$\begin{cases} y'(t) &= \lambda y(t); \\ y(0) &= y_0. \end{cases}$$

Para cada método de Runge-Kutta implícito aplicado a este P.V.I., existe uma $\phi : \mathbb{C} \rightarrow \mathbb{C}$ tal que

$$y_n = \phi(h\lambda)^n y_0,$$

onde $h \in (0, \infty)$ é o passo de tempo e $n \in \mathbb{N} \cup \{0\}$. Além disso, se ϕ é tal função para um método (de Runge-Kutta) de Gauss-Legendre, então

$$\{z \in \mathbb{C} \mid \Re(x) < 0\} \subset \{z \in \mathbb{C} \mid |\phi(z)| < 1\},$$

i.e., eles são A-estáveis.

Observação 7. *As funções de estabilidade ϕ de métodos de Runge-Kutta implícitos são funcionais racionais complexas, que podem ter valor absoluto menor que um em regiões ilimitadas do plano complexo.*

2.4 Métodos de passos múltiplos (lineares)

Seja $\lambda \in \mathbb{C}$ e $f(t, y) = \lambda y$. A expressão de avanço de passo de um método de passos múltiplos (linear) é

$$y_{n+1} = \sum_{i=0}^s a_i y_{n-i} + h \sum_{i=-1}^s b_i f(t_{n-i}, y_{n-i}) = \sum_{i=0}^s a_i y_{n-i} + h \sum_{i=-1}^s b_i \lambda y_{n-i},$$

para $a_i, b_i \in \mathbb{C}$. Reordenando os termos, chegamos na expressão

$$(1 - h\lambda b_{-1}) y_{n+1} - \sum_{i=0}^s (a_i - h\lambda b_i) y_{n-i} = 0.$$

Como visto anteriormente, o polinômio característico dessa relação de recorrência linear com coeficientes constantes é

$$\phi(z, w) = (1 - zb_{-1})w - \sum_{i=0}^s (a_i - zb_i)w^{s-i},$$

onde $h\lambda =: z \in C$ e escrevemos ϕ como função também de z para enfatizar que este polinômio depende deste fator, i.e., para cada $z \in \mathbb{C}$ fixado, a ϕ como uma função apenas de $w \in \mathbb{C}$ é o polinômio característico.

Agora, relembrem que a solução de uma relação de recorrência como a que acabamos de ver é uma combinação linear de termos da forma

$$\xi_i^n, \quad n\xi_i^n, \quad |\xi_i|^n \sin(n\theta), \quad |\xi_i|^n \cos(n\theta),$$

onde $\xi_i \in \mathbb{C}$ são as raízes do polinômio característico, $\theta \in R$ e os dois últimos termos são usados quando buscamos uma soluções reais apenas. Note que cada um desses termos só vai a 0 quando $n \rightarrow \infty$ se $|\xi_i| < 1$. Isso motiva a definição de A-estabilidade a seguir.

Definição 5. *Sejam $y_0 \in \mathbb{R}$, $\lambda \in \mathbb{C}$ e considere o P.V.I.*

$$\begin{cases} y'(t) &= \lambda y(t); \\ y(0) &= y_0. \end{cases}$$

Para cada método de passos múltiplos (linear), seja $\phi : \mathbb{C} \times \mathbb{C} \rightarrow \mathbb{C}$ seu polinômio característico na segunda entrada, com a dependência em $h\lambda := z \in C$ na primeira entrada ($h \in (0, \infty)$ é o passo de tempo). Definimos o domínio de estabilidade daquele método como sendo o conjunto

$$\{z \in \mathbb{C} \mid \phi(z, w) = 0 \implies |w| < 1\}.$$

A definição de A-estabilidade para esses métodos é a mesma para os métodos de Runge-Kutta: um método é A-estável se seu domínio de estabilidade contém todo o semiplano esquerdo do plano complexo.

Teorema 3 (Segunda Barreira de Dahlquist). *Nenhum método de passos múltiplos (linear) explícito é A-estável. Além disso, a maior ordem de um método de passos múltiplos (linear) implícito A-estável é 2. Dentre tais métodos, o que tem a menor constante de erro é a regra do trapézio.*

Observação 8. *Ao longo das últimas aulas, definimos o domínio de estabilidade para métodos de Runge-Kutta e métodos de passos múltiplos (lineares) utilizando a E.D.O. $y' = \lambda y$ como equação "modelo". Por causa desta escolha de E.D.O., tais regiões são comumente chamadas de domínio de estabilidade **linear**. Os domínios de estabilidade para equações "modelo" não-lineares ainda são objeto de muita pesquisa (e a E.D.O. que parece funcionar bem é $y'' + w^2 \sin(y) = 0$).*

3 Relação entre convergência, consistência e estabilidade

Vamos nos lembrar das definições de convergência e consistência vistas anteriormente.

Definição 6 (Convergência). *Um método é convergente quando seu erro global vai para zero quando o passo de tempo vai para zero.*

Definição 7 (Consistência). *Um método é consistente se seu erro de truncamento local $T(n, h)$ satisfaz*

$$\lim_{h \rightarrow 0} \frac{T(n, h)}{h} = 0,$$

onde $h \in (0, \infty)$ é o passo de tempo.

Podemos também definir formalmente a estabilidade de um método de diferenças finitas. No entanto, para os propósitos deste curso, a seguinte definição informal será o suficiente:

Sejam $t_0 \in \mathbb{R}$, $y_0 \in \mathbb{C}$, $f : \mathbb{R} \times \mathbb{C} \rightarrow \mathbb{C}$ e considere o P.V.I.

$$\begin{cases} y'(t) = f(t, y); y(t_0) = y_0. \end{cases}$$

Além disso, considere um método numérico para aproximar esta E.D.O. para qual vale a equação

$$y_n = \mathcal{L}_{n,h} y_0,$$

onde $n \in \mathbb{N} \cup \{0\}$ é o passo atual, $h \in (0, \infty)$ é o passo de tempo e $\mathcal{L}_{n,h}$ é um operador linear proveniente da linearização de f . Dizemos que tal método é estável se existe $M \in \mathbb{R}$ tal que

$$\|\mathcal{L}_{n,h}\| < M,$$

para todo $n \in \mathbb{N} \cup \{0\}$, $h \in (0, \infty)$.

Com essa última definição informal, podemos enunciar o poderoso teorema de equivalência.

Teorema 4 (Teorema da Equivalência de Lax). *Um método de diferenças finitas (para E.D.O.s) consistente é convergente se, e somente se, ele é estável.*